

Universidad de Guadalajara

Ingeniería de Datos

Análisis de Contenido en Plataformas de Streaming

Aplicación de la Jerarquía DIKW

Sebastian Sanchez Espinosa

Código: 217725106

Guadalupe Jeanette Gonzalez Diaz

27 de mayo de 2026

Jerarquía DIKW aplicada al análisis de plataformas de streaming

Introducción

Las plataformas de streaming manejan miles de títulos y necesitan entender cuáles generan mayor audiencia. Sin embargo, tener muchos datos no garantiza buenas decisiones. Para que los datos realmente sirvan, tienen que pasar por un proceso de transformación que los convierte primero en información, luego en conocimiento y finalmente en sabiduría. Este proceso se conoce como DIKW. El sistema desarrollado en este proyecto aplica esa jerarquía al catálogo de contenido de diez plataformas de streaming, con el objetivo de predecir cuáles títulos tendrán éxito comercial.

Dato

En la base de DIKW están los datos crudos. En este caso, cada título registrado en el sistema tiene asociado un conjunto de hechos: el nombre, la plataforma en que está disponible, el género principal, el año de lanzamiento, la clasificación de contenido, el presupuesto estimado, los votos del público en sitios de reseñas y la cantidad de horas que fue visto. Por sí solos, estos números y textos no dicen nada. Saber que un título tiene una calificación de 7.2 o que fue lanzado en 2018 no permite tomar ninguna decisión concreta. Son simplemente registros que necesitan contexto para tener valor.

Información

Cuando los datos se limpian, se combinan y se organizan, se convierten en información. Por ejemplo, al agrupar los títulos por plataforma se puede calcular el promedio de calificación de cada una, el porcentaje de títulos exitosos o la distribución de géneros disponibles. Un título con 7.2 de calificación dentro de una plataforma donde el promedio es 6.5 ya tiene un significado diferente al mismo título en una plataforma donde el promedio es 8.0. Ese contexto es lo que transforma el dato en información. En este proyecto, esa etapa incluye la limpieza de registros incompletos, la creación de variables derivadas como la antigüedad del título o el tamaño del elenco, y la generación de resúmenes por plataforma, género y país.

Conocimiento

La información, cuando se analiza en conjunto, permite descubrir patrones. Ahí es donde entra el conocimiento. A través de modelos de clasificación y agrupación, el sistema identifica qué combinaciones de características tienden a producir títulos con alta audiencia. Por

ejemplo, se puede observar que ciertos géneros en determinadas plataformas concentran más horas vistas, o que los títulos con mayor número de premios no siempre coinciden con los más vistos. Estos patrones no son obvios mirando los datos uno por uno; emergen del análisis. El conocimiento generado permite entender la lógica detrás del éxito de un título.

Sabiduría

El nivel más alto de DIKW ocurre cuando el conocimiento se usa para tomar decisiones. En este sistema, esa etapa se hace en una herramienta interactiva donde es posible ingresar las características de un título que aún no existe y obtener una estimación de si tendrá éxito o no. Un productor de contenido o un ejecutivo de una plataforma puede usar esa herramienta para comparar opciones antes de invertir en una producción.

Conclusión

El recorrido desde el dato crudo hasta la sabiduría no es automático. Requiere decisiones sobre cómo limpiar los datos, qué variables construir, qué modelos usar y cómo presentar los resultados. Cada etapa agrega una capa de significado que la anterior no tenía. Este proyecto demuestra que el valor de los datos no está en la cantidad sino en el proceso que los transforma en algo útil para quien toma decisiones.

Planteamiento del Problema

Descripción del caso de estudio

Las plataformas de streaming compiten por la atención del público con catálogos cada vez más grandes. Decidir qué contenido producir o adquirir implica inversiones significativas, y no todos los títulos logran el nivel de audiencia esperado. El problema central es que las decisiones editoriales suelen basarse en criterios subjetivos o en la experiencia de quienes las toman, sin un respaldo en datos históricos.

Este proyecto aborda ese problema construyendo un sistema que analiza el catálogo de diez plataformas de streaming, con más de 15,000 títulos registrados entre 1980 y 2026. El sistema utiliza características de cada título, como el género, el año de producción, el presupuesto, las calificaciones del público y la crítica, y la cantidad de horas vistas, para identificar qué factores van de la mano con el éxito comercial.


El objetivo es, por un lado, describir el panorama actual del contenido en streaming mediante análisis exploratorio y visualizaciones. Por otro, ofrecer una herramienta predictiva que permita estimar la probabilidad de éxito de un título antes de que sea lanzado, apoyándose en modelos de clasificación y agrupación entrenados con los datos históricos disponibles.

Miniespecificación de Requerimientos

La siguiente tabla describe los requerimientos técnicos del sistema en términos de latencia, frescura, volumen y disponibilidad.

Dimensión	Descripción	Valor para este sistema
Latencia	Tiempo de respuesta aceptable para obtener resultados.	El entrenamiento de modelos se ejecuta de forma periódica y puede tardar varios minutos. Las consultas del tablero de visualización responden en menos de tres segundos.
Frescura	Qué tan actualizados deben estar los datos.	El catálogo se actualiza una vez por temporada o cuando hay cambios relevantes en la oferta de las plataformas. No se requiere actualización diaria.
Volumen	Cantidad de datos que el sistema maneja.	Aproximadamente 15,000 registros con 25 columnas cada uno. El tamaño total es menor a 5 MB, lo que permite procesarlo en memoria sin infraestructura especializada.
Disponibilidad	Tiempo en que el sistema debe estar operativo.	El sistema corre de forma local. No existe un nivel de servicio formal. Está disponible cada vez que se ejecuta el entorno de trabajo del analista.

Mapa de Flujo de Datos




Modelado de Datos y Normalización

Justificación de la normalización

El archivo de datos original almacena toda la información en una sola tabla. Esto genera dos tipos de problemas. El primero es que los campos *genres* y *cast* contienen listas de valores separados por comas dentro de una sola celda, lo que viola la Primera Forma Normal (1FN), que exige que cada campo contenga un único valor. El segundo es que datos como el nombre de la plataforma o la empresa productora se repiten en cada registro, generando redundancias que violan la Tercera Forma Normal (3FN).

El esquema propuesto resuelve estos problemas separando las entidades en tablas independientes, creando tablas para las relaciones de muchos a muchos y trasladando los valores repetidos a tablas de referencia.

Diagrama Entidad-Relación



Diccionario de Datos

A continuación se documenta cada tabla del esquema normalizado con sus campos, tipos de dato, restricciones y descripción.

Tabla: Titulo

Campo	Tipo	Restricción	Descripción
show_id	VARCHAR(10)	PK, NOT NULL	Identificador único del título
title	VARCHAR(200)	NOT NULL	Nombre del título
type	VARCHAR(20)	NOT NULL	Tipo: Movie o TV Show
platform_id	INT	FK, NOT NULL	Referencia a la plataforma
primary_genre_id	INT	FK	Género principal del título
company_id	INT	FK	Empresa productora
director	VARCHAR(100)	NULL	Nombre del director
country	VARCHAR(50)	NULL	País de producción
language	VARCHAR(50)	NULL	Idioma principal
release_year	INT	NOT NULL	Año de estreno
date_added	DATE	NULL	Fecha de incorporación a la plataforma
rating	VARCHAR(10)	NULL	Clasificación de contenido (R, PG-13, etc.)
duration_minutes	INT	NULL	Duración en minutos (películas)
num_seasons	INT	NULL	Número de temporadas (series)
num_episodes	INT	NULL	Número de episodios (series)
description	TEXT	NULL	Sinopsis del título

Tabla: Plataforma

Campo	Tipo	Restricción	Descripción
platform_id	INT	PK, NOT NULL	Identificador único de la plataforma
nombre	VARCHAR(50)	NOT NULL, UNIQUE	Nombre de la plataforma (Netflix, Disney+, etc.)

Tabla: Género

Campo	Tipo	Restricción	Descripción
genre_id	INT	PK, NOT NULL	Identificador único del género
nombre	VARCHAR(50)	NOT NULL, UNIQUE	Nombre del género (Drama, Thriller, etc.)

Tabla: TituloGenero

Campo	Tipo	Restricción	Descripción
show_id	VARCHAR(10)	PK, FK	Referencia al título
genre_id	INT	PK, FK	Referencia al género

Tabla: Persona

Campo	Tipo	Restricción	Descripción
person_id	INT	PK, NOT NULL	Identificador único de la persona
nombre	VARCHAR(100)	NOT NULL	Nombre completo del actor o directivo

Tabla: TituloPersona

Campo	Tipo	Restricción	Descripción
show_id	VARCHAR(10)	PK, FK	Referencia al título
person_id	INT	PK, FK	Referencia a la persona
rol	VARCHAR(20)	NOT NULL	Rol en el título (Actor, Director, etc.)

Tabla: EmpresaProductora

Campo	Tipo	Restricción	Descripción
company_id	INT	PK, NOT NULL	Identificador único de la empresa
nombre	VARCHAR(100)	NOT NULL, UNIQUE	Nombre de la empresa productora

Tabla: Metricas

Campo	Tipo	Restricción	Descripción
show_id	VARCHAR(10)	PK, FK	Referencia al título
imdb_rating	DECIMAL(3,1)	NULL	Calificación en IMDb (0.0 a 10.0)
rotten_tomatoes	INT	NULL	Puntuación en Rotten Tomatoes (0 a 100)
imdb_votes	INT	NULL	Número de votos registrados en IMDb
budget_usd	DECIMAL(10,2)	NULL	Presupuesto estimado en millones de dólares
awards_won	INT	NULL	Cantidad de premios obtenidos
hours_watched	DECIMAL(10,2)	NULL	Horas vistas acumuladas en la plataforma

Gestión y Transformación

Lógica de Transformación

La transformación de los datos crudos en información útil para los modelos se realiza en dos etapas: limpieza y construcción de variables.

Etapla 1: Limpieza de datos

Regla	Campo(s) afectado(s)	Justificación
Eliminar filas duplicadas por identificador único	show_id	Evitar que un mismo título distorsione las frecuencias y el entrenamiento del modelo.
Convertir fecha de texto a tipo fecha	date_added	Permite calcular diferencias de tiempo (días en plataforma, mes de incorporación).
Rellenar director con "Sin datos"	nulo director	Las series pueden no tener un director único. El valor nulo se reemplaza para evitar errores en el procesamiento.
Codificar variables categóricas con etiquetas numéricas	platform, primary_genre, rating	Los modelos de aprendizaje automático requieren entradas numéricas. Se asigna un entero único a cada categoría.

Etapla 2: Construcción de variables derivadas

Variable creada	Fórmula / Criterio	Justificación
es_pelicula	1 si type = “Movie”, 0 si no	Convierte el tipo de contenido en una variable binaria utilizable por los modelos.
cantidad_generos	Número de géneros separados por coma en el campo genres	Títulos con más géneros pueden tener mayor alcance de audiencia.
tamano_elenco	Número de actores separados por coma en el campo cast	Un elenco más grande puede indicar mayor inversión y visibilidad.
antiguedad	$2026 - \text{release_year}$	Captura cuán reciente es el contenido en relación al año de referencia.
es_reciente	1 si $\text{release_year} \geq 2020$, 0 si no	Marca los títulos estrenados en los últimos años como potencialmente más relevantes.
mes_agregado	Mes extraído de date_added	Captura posibles patrones estacionales en la incorporación de contenido.
dias_en_plataforma	Días desde date_added hasta la fecha actual	Títulos con más tiempo disponibles acumulan más horas vistas naturalmente.
votos_log	$\log(1 + \text{imdb_votes})$	Los votos de IMDb tienen una distribución muy sesgada. La transformación logarítmica la comprime y mejora el entrenamiento.
presupuesto_log	$\log(1 + \text{budget_million_usd})$	+ Misma razón que votos_log. Los presupuestos nulos se tratan como cero antes de la transformación.
tiene_presupuesto	1 si budget_million_usd no es nulo, 0 si no	Indica si el presupuesto fue reportado, ya que la ausencia del dato es informativa en sí misma.

Etapla 3: Variables objetivo

Variable	Criterio	Justificación
is_hit	1 si $\text{hours_watched_million} \geq$ mediana del conjunto completo	Define éxito comercial de forma relativa al catálogo, evitando un umbral arbitrario.
imdb_clase	Bajo si $\text{IMDb} < 6.1$, Medio si $6.1 \leq \text{IMDb} \leq 7.6$, Alto si $\text{IMDb} > 7.6$	Los umbrales corresponden al percentil 25 y 75 del conjunto, generando tres clases balanceadas.

Especificación de Orquestación

El sistema se ejecuta como una secuencia de pasos.

El pipeline se organiza en tres niveles de ejecución.

El primer nivel parte del archivo de datos crudo y puede ejecutarse en paralelo: el notebook **01_eda** realiza el análisis exploratorio leyendo directamente el CSV, mientras que el notebook **02_preprocesamiento** aplica todas las transformaciones y guarda los archivos procesados en disco.

El segundo nivel depende completamente de que **02** haya terminado. Una vez disponibles los datos procesados, los cuatro notebooks de modelos pueden correr en paralelo sin depender entre sí: **03_decision_tree** y **04_svm** clasifican la variable *is_hit*, **05_neural_network** clasifica *imdb_clase* y **06_kmeans** agrupa el contenido en clusters.

El tercer nivel requiere que todos los modelos estén entrenados. El notebook **07_comparacion_modelos** consolida las métricas de los cuatro modelos en una tabla comparativa. Finalmente, el **Dashboard** consume los archivos de **02** y los modelos guardados de **03** a **06** para ofrecer visualizaciones interactivas y el predictor de éxito en tiempo real.

Propuesta de Valor

El pipeline transforma datos crudos del catálogo de streaming en modelos capaces de responder preguntas concretas de negocio con evidencia cuantitativa.

Decisiones habilitadas por el sistema

1. Evaluar el potencial comercial de un título antes de adquirirlo. Los modelos de clasificación binaria (Árbol de Decisión y SVM) predicen si un título alcanzará el umbral de horas vistas que lo clasifica como *hit*. Con una exactitud superior al 91 % y un área bajo la curva ROC de 0.97, el sistema permite filtrar propuestas de adquisición con criterios objetivos en lugar de criterios subjetivos.

2. Anticipar la calidad percibida por la audiencia. La red neuronal predice la categoría de calificación IMDb (Bajo, Medio o Alto) a partir de características disponibles antes del lanzamiento. Con un F1-macro de 0.68, el modelo captura patrones que asocian género, plataforma, presupuesto y elenco con la percepción del público, lo que permite identificar títulos con potencial de crítica positiva.

3. Identificar segmentos naturales en el catálogo. El análisis de agrupamiento con K-Means ($k=4$, silhouette=0.181) muestra que el catálogo tiene cuatro perfiles de contenido con características distintas en términos de calificaciones, horas vistas, presupuesto y premios. Conocer a qué perfil pertenece un título orienta las decisiones de promoción y posicionamiento dentro de la plataforma.

4. Comparar plataformas con criterios objetivos. La comparación entre las 10 plataformas del catálogo, usando métricas como promedio IMDb, porcentaje de hits y premios ganados, ofrece una visión competitiva que no depende de la percepción. Esto es útil tanto para plataformas que buscan mejorar su catálogo como para productoras que eligen dónde distribuir su contenido.

La siguiente tabla resume el desempeño de los modelos de clasificación:

Modelo	Tarea	Exactitud	F1-macro	ROC-AUC
Árbol de Decisión	is_hit	0.914	0.91	0.972
SVM	is_hit	0.912	0.91	0.975
Red Neuronal (TF)	imdb_clase	0.676	0.684	multiclase




Figura 1: Curvas ROC de los modelos de clasificación binaria. Ambos superan un área de 0.97, lo que indica una capacidad de discriminación alta entre títulos que serán hits y los que no.

Prototipo de Visualización: Dashboard Interactivo

El prototipo de visualización es un dashboard desarrollado en Streamlit que integra todos los resultados del proyecto en una interfaz web interactiva. El dashboard está compuesto por siete secciones, cada una orientada a responder preguntas específicas de negocio a partir de los datos y modelos entrenados.